




Católica del Norte
Fundación Universitaria

Metodologías para Proyectos Data Mining

Elemento de competencia 1



Elemento de competencia 1

Nombre del curso	Metodologías para Proyectos Data Mining
Programa	Ingeniería en Analítica de Datos
Facultad	Ingeniería y Ciencias Ambientales
Elemento de competencia	Identificar los elementos y etapas de un proyecto de minería de datos para la obtención, preparación y comprensión de los datos requeridos en la organización.
Temas	Tema 1. Introducción a las metodologías para proyectos de minería de datos. Tema 2. Selección de fuentes y reconocimiento de datos anómalos.

Tema 1. Introducción a las metodologías para proyectos de minería de datos

Actualmente, una de las disciplinas que contribuye en mayor medida a generar valor en las organizaciones es la minería de datos (*data mining*), ya que permite analizar grandes volúmenes de datos, mediante la aplicación de técnicas provenientes de la estadística, el aprendizaje automático y la gestión de bases de datos, no para acumular información,



sino para transformarla en conocimiento útil que ayude a comprender diferentes fenómenos y a orientar la acción organizacional.

Ahora bien, este proceso de transformación de los datos no ocurre de manera espontánea ni depende únicamente del dominio técnico de quien lo ejecuta, sino que requiere un camino ordenado que indique por dónde comenzar, qué actividades desarrollar en cada etapa y cómo verificar que los resultados respondan al problema planteado. Allí es donde cobran relevancia las metodologías para proyectos de minería de datos, que son los marcos de trabajo que estructuran el ciclo de vida completo de un proyecto, desde la comprensión del problema hasta la entrega del conocimiento generado.

En el ámbito de la analítica, existen diversas metodologías que orientan el desarrollo de proyectos de minería de datos, las cuales surgieron en contextos distintos y ponen el énfasis en aspectos diferentes. Entre las más reconocidas se encuentran las siguientes:

- **KDD (*Knowledge Discovery in Databases*)**: fue definido por Fayyad et al. (1996) como el proceso no trivial de identificar patrones válidos, novedosos, potencialmente útiles y comprensibles en los datos, mediante cinco etapas, que son la selección, el preprocesamiento, la transformación, la minería de datos y la evaluación e interpretación de los resultados. Este es el proceso conceptual de referencia del que derivan las demás propuestas y en él, como puede verse, la minería de datos es una etapa dentro de un proceso mayor.
- **SEMMA (*Sample, Explore, Modify, Model, Assess*)**: esta metodología fue desarrollada por el instituto SAS y también organiza el trabajo en cinco etapas, que son el muestreo, la exploración, la modificación, el modelado y la evaluación. Su énfasis está en los aspectos técnicos del tratamiento de los datos y la

construcción de modelos, más que en la comprensión del contexto organizacional.

- **CRISP-DM (*Cross-Industry Standard Process for Data Mining*)**: fue creada por un consorcio de empresas a finales de los años noventa, quienes propusieron seis fases que abarcan el ciclo completo del proyecto, las cuales son la comprensión del negocio, la comprensión de los datos, la preparación de los datos, el modelado, la evaluación y el despliegue.
- **Enfoques recientes**: con la consolidación de la ciencia de datos han surgido propuestas como TDSP (*Team Data Science Process*), que se orienta al trabajo colaborativo en equipos, así como adaptaciones de CRISP-DM que incorporan principios de las metodologías ágiles.

De todas ellas, CRISP-DM es la metodología más adoptada, ya que presenta una visión integral que abarca el ciclo de vida completo de un proyecto de analítica y no únicamente los componentes técnicos; además, porque puede transferirse a cualquier sector y tecnología. A continuación, entonces, se ahonda en ella.

El modelo CRISP-DM

El modelo CRISP-DM surgió de la colaboración entre la industria y la academia, a finales de la década de 1990, para dar respuesta a una necesidad específica, que, en palabras de Shearer (2000), era crear un estándar práctico que cualquier organización pudiera aplicar en los proyectos de minería de datos, independientemente de su sector o de las herramientas tecnológicas disponibles. Gracias a esta apertura adquirió una adopción global, además, porque, a diferencia de los modelos más técnicos, toda la lógica del proceso se articula a partir de un problema de



negocio, lo cual garantiza que el trabajo esté orientado a generar valor real.

Con base en ello, como se mencionó anteriormente, este modelo propone seis fases interconectadas, que se van a explicar a continuación, tomando como ejemplo el caso hipotético de una cadena de supermercados que tiene presencia en varias ciudades, pero se queda frecuentemente sin existencias de ciertos productos antes de que llegue el siguiente pedido al proveedor, lo que genera pérdidas de ventas y clientes insatisfechos, por lo que la dirección decide iniciar un proyecto de minería de datos para anticipar qué productos tienen mayor riesgo de agotarse y en qué tiendas. Las fases que se siguen, en este orden de idea, son las siguientes:

- 1. Comprensión del negocio:** consiste en establecer los objetivos del proyecto desde la perspectiva organizacional y definir los criterios con los que se va a medir su éxito. En el caso de la cadena de supermercados, en esta fase, el equipo analítico se reúne con los gerentes de operaciones y logística para precisar el problema y concuerdan en que no se trata de predecir todas las ventas, sino específicamente de identificar, con al menos cinco días de anticipación, qué referencias de producto y en qué tiendas van a estar por debajo del umbral mínimo de inventario. Este criterio concreto de cinco días y umbral mínimo es el que va a definir el éxito del proyecto.
- 2. Comprensión de los datos:** consiste en una exploración inicial que permite identificar qué información está disponible, en qué condiciones se encuentra y qué limitaciones presenta. Por ejemplo, en el caso de la cadena de supermercados, el equipo identifica las fuentes disponibles, como el sistema ERP corporativo, que registra las ventas diarias por tienda y producto; el sistema de gestión de



inventarios; y algunos datos externos como el calendario de festividades nacionales y regionales, que históricamente afectan los patrones de consumo. Además, se descubre que los registros de ventas de dos tiendas tienen inconsistencias por migraciones de sistema realizadas el año anterior.

- 3. Preparación de los datos:** esta es normalmente la fase más extensa, ya que aquí se limpian, integran y transforman los datos para que sean aptos para el modelado. Por lo tanto, en el caso de la cadena de supermercados, se limpian las inconsistencias encontradas, se integran las tres fuentes en un único conjunto de datos estructurado, se construyen variables nuevas como la velocidad de rotación semanal de cada producto y se normalizan las escalas para que las variables sean comparables entre sí.
- 4. Modelado:** aquí se seleccionan y aplican las técnicas de minería de datos pertinentes, ajustando sus parámetros, con el fin de optimizar los resultados; con frecuencia se prueba más de una técnica sobre el mismo conjunto de datos, ya que distintos algoritmos pueden capturar diferentes aspectos del fenómeno estudiado. Por ejemplo, en el caso de la cadena de supermercados, se ponen a prueba dos algoritmos: un modelo de series de tiempo, para capturar la estacionalidad de las ventas, y un modelo de clasificación, para identificar las combinaciones producto-tienda con mayor probabilidad de desabastecimiento en los próximos cinco días.
- 5. Evaluación:** aquí se evalúa si los resultados obtenidos responden realmente a los objetivos planteados al inicio. En el caso de la cadena de supermercados, el modelo identifica correctamente el 87% de los casos de desabastecimiento reales del último trimestre; sin embargo, el equipo detecta que el modelo falla en productos de temporada que no tienen suficiente historial. Esto obliga a regresar



a la fase de preparación para incorporar variables adicionales relacionadas con el calendario comercial.

6. Despliegue: por último, se convierte el conocimiento generado en algo utilizable por la organización, como un informe, un sistema automatizado o una recomendación de política. Por ejemplo, en el caso que se ha trabajado, el modelo se integra al sistema de gestión de inventarios de la empresa, generando alertas automáticas cada lunes para los responsables de compras en cada tienda, con una lista priorizada de productos que requieren reabastecimiento urgente.

Como pudo verse en el ejemplo, otra de las características destacables del modelo CRISP-DM es su carácter iterativo; es decir que las fases no se ejecutan necesariamente en un orden lineal y definitivo, sino que pueden repetirse o retomarse cuantas veces sea necesario a medida que surgen nuevos hallazgos, ya que es habitual que durante el modelado se descubran problemas en los datos que obligan a regresar a la fase de preparación o que en la evaluación se descubra que el problema de negocio estaba mal formulado y se deba volver al principio. Esto no es una debilidad o un fracaso, sino una corrección natural que mejora la calidad del resultado.

A ello puede sumársele que este modelo también posee un valor organizacional que trasciende lo estrictamente metodológico, ya que funciona como un lenguaje común entre los equipos técnicos y los tomadores de decisiones, lo que facilita la comunicación, la asignación de recursos y el seguimiento del proyecto en cada una de sus etapas.

CRISP-DM, por lo tanto, al igual que todas las metodologías para proyectos de minería de datos, no constituye una simple secuencia de pasos, sino un marco de trabajo que, si se aborda con el rigor necesario, realmente ayuda a convertir los datos organizacionales en conocimiento



accionable. De allí la importancia de ahondar en cada una de sus fases y en la lógica que las articula, lo cual se hará a lo largo de este curso.

Recursos de profundización

En las secciones 3.2 y 3.3 del siguiente libro, de la página 46 a la 48, se presenta un análisis comparativo de las principales metodologías de minería de datos, incluyendo CRISP-DM y SEMMA, examinando sus similitudes y diferencias en etapas clave como la planeación del proyecto, el procesamiento de datos y el análisis.

- Aguirre Mayorga, H. S. (2016). *Minería de procesos: fundamentos y metodología de aplicación*. Editorial Pontificia Universidad Javeriana. www.061051aqx-y-https-elibro-net.ucn.metaproxy.org

A continuación, se presenta un estudio comparativo entre las principales metodologías vigentes para proyectos de minería de datos, como KDD, CRISP-DM, SEMMA y Catalyst (P3TQ), evaluando las ventajas y desventajas de cada una. Su lectura permite ampliar la perspectiva más allá de un único marco metodológico y comprender por qué CRISP-DM se consolidó como el estándar más adoptado.

- Moine, J. M., Haedo, A. S. y Gordillo, S. E. (2011). *Estudio comparativo de metodologías para minería de datos*. EN *XIII Workshop de Investigadores en Ciencias de la Computación* (pp. 278-281). Red de Universidades con Carreras en Informática (RedUNCI). www.sedici.unlp.edu.ar



Tema 2. Selección de fuentes y reconocimiento de datos anómalos

Como se explicó en el tema anterior, el modelo CRISP-DM toma como punto de partida la comprensión de un problema de negocio para direccionar el proyecto de minería de datos hacia respuestas que realmente tengan utilidad práctica. Para ello, una vez se ha identificado el problema que se desea abordar y se ha definido un plan de trabajo, lo primero que debe hacerse es resolver dos preguntas igualmente decisivas; la primera es de dónde se van a obtener los datos que permitan responder a ese problema y la segunda consiste en reconocer, una vez identificadas esas fuentes, qué tan confiables son los datos que contienen, pues ningún algoritmo, por sofisticado que sea, puede compensar información que llega distorsionada por valores atípicos, registros faltantes o inconsistencias.

Para responder a la primera pregunta, entonces, es necesario entender que las fuentes de donde se toman los datos pueden ser internas o externas a la organización. Las fuentes internas son aquellas donde se albergan datos que la organización ya genera como parte de su operación cotidiana y que, bien gestionados, constituyen una base sólida para el análisis; entre ellas se encuentran, por ejemplo, los sistemas ERP, CRM, las bases de datos transaccionales, los registros operativos o los logs de sistemas.

Por su parte, las fuentes externas son aquellas que amplían el horizonte del análisis, como los datos abiertos de entidades gubernamentales, las APIs públicas, los informes sectoriales, las redes sociales y los proveedores especializados de datos, que pueden aportar variables de contexto que las fuentes internas no recogen y que, en muchos casos, son determinantes para la calidad de un modelo. Por ejemplo, una empresa de retail que analiza sus ventas internas sin



considerar datos macroeconómicos externos o un hospital que modela la demanda de servicios sin incorporar datos epidemiológicos regionales, están trabajando con una visión parcial del fenómeno.

En este sentido, el criterio para seleccionar las fuentes no debe ser la disponibilidad, sino la pertinencia; es decir que hay que preguntarse ¿qué información es estrictamente necesaria para responder el problema planteado? y responderla con rigor, evitando subutilizar datos valiosos que ya existen en la organización o sobrecargar el proceso con información irrelevante que aumenta la complejidad sin aportar valor al análisis.

Ahora bien, una vez identificadas las fuentes de datos que sean más pertinentes para el problema planteado, debe accederse a ellas, reconociendo qué variables contienen, en qué formato se encuentran y qué volumen representan. En este acercamiento, se empieza a evaluar qué tan confiables son realmente los datos disponibles y a identificar posibles irregularidades en su comportamiento, ya que los datos casi nunca se comportan de manera homogénea, sino que en todo conjunto hay observaciones que se alejan del patrón general, que parecen no encajar o que rompen la regularidad esperada.

En este sentido, puede hablarse de datos anómalos, también conocidos como *outliers*, que son observaciones que se desvían de manera significativa del comportamiento general del conjunto de datos al que pertenecen. Según Chandola et al. (2009) pueden identificarse tres tipos principales de anomalías:

- **Las anomalías puntuales:** son observaciones aisladas que difieren del resto, como un consumo eléctrico diez veces superior al promedio en una sola lectura.
- **Las anomalías contextuales:** son valores que solo resultan extraños en un contexto particular; por ejemplo, una temperatura



de cinco grados es normal en invierno, pero anómala en pleno verano.

- **Las anomalías colectivas:** son grupos de observaciones que, individualmente, parecen razonables, pero que en conjunto evidencian un comportamiento inusual, como una secuencia de transacciones pequeñas pero coordinadas que podría indicar un fraude.

Las causas de estas anomalías pueden ser varias, como los errores de medición en sensores, los errores humanos en el registro, los fallos en la integración entre sistemas o simplemente son eventos reales excepcionales que el modelo debería poder captar. Es muy importante tener en cuenta esta última posibilidad, ya que no todo dato anómalo debe eliminarse; de hecho, en ámbitos como la detección de fraudes, el diagnóstico médico o el monitoreo industrial, las anomalías son precisamente el objeto del análisis y eliminarlas sería privar al modelo de la información más valiosa que puede ofrecerle el conjunto de datos. Por eso, el primer principio frente a una anomalía no es removerla, sino comprenderla.


Métodos para la detección de anomalías

Para identificar estos valores atípicos, tradicionalmente se usan métodos estadísticos gracias a su simplicidad y transparencia. Entre ellos se encuentra, por ejemplo, el Z-score que es una medida de estandarización que ayuda a medir a cuántas desviaciones estándar se encuentra una observación respecto de la media; teniendo en cuenta que los valores superiores a tres o inferiores a menos tres suelen considerarse atípicos cuando la distribución se aproxima a la normal. Este concepto se ilustra en la figura 1.



Figura 1

Detección de valores atípicos mediante Z-score




Además de ello, cuando la distribución es asimétrica o presenta colas pesadas, resulta más apropiado usar el rango intercuartílico (IQR), que define como atípicos los valores que se encuentran por debajo del primer cuartil o por encima del tercero en una proporción determinada del IQR, típicamente 1.5 veces. Un cuartil, en este sentido, es cada uno de los tres valores que dividen un conjunto de datos ordenados en cuatro partes iguales: el primer cuartil (Q1) deja el 25% de los datos por debajo de él, el segundo cuartil (Q2) corresponde a la mediana y divide los datos en dos mitades iguales y el tercer cuartil (Q3) deja el 75% de los datos por debajo. Por lo tanto, el rango intercuartílico se calcula como $IQR = Q3 - Q1$ y representa la dispersión del 50% central de los datos, siendo robusto frente a la influencia de valores extremos.

Estos tres cuartiles, junto con los valores mínimo y máximo dentro de los límites esperados, se representan visualmente en el diagrama de caja (*boxplot*), que es una herramienta que permite identificar de manera

inmediata la distribución de los datos y la presencia de valores atípicos. La figura 2 ilustra un diagrama de cajas y la visualización de los puntos críticos.

Figura 2

Diagrama de caja con presencia de valores atípicos



La visualización, en este orden de ideas, es una estrategia que se puede aplicar como primer paso para detectar los datos atípicos, sobre todo mediante gráficos como los diagramas de caja, los histogramas y los gráficos de dispersión, que permiten identificar visualmente puntos que se separan del comportamiento general antes de aplicar cualquier técnica formal. Sin embargo, tanto la visualización como los métodos estadísticos descritos anteriormente son limitados cuando los datos tienen muchas dimensiones, porque la noción de “distancia respecto al centro” pierde sentido a medida que aumenta la cantidad de variables.

Para superar esta limitación, entonces, existen algunos métodos más sofisticados, propios del aprendizaje automático, que ayudan a detectar anomalías a partir de la estructura de los datos sin asumir distribuciones específicas. El primero que puede señalarse es *Isolation Forest*, que construye árboles aleatorios donde las observaciones

anómalas tienden a aislarse en menos divisiones que las observaciones normales. Al respecto señalan Liu et al. (2008) que la mayoría de los enfoques construyen primero un perfil de lo que es normal y luego identifican como anómalos los puntos que no se ajustan a ese perfil; en cambio, *Isolation Forest* propone una lógica distinta y, en lugar de modelar lo normal, aísla directamente lo anómalo, aprovechando que las observaciones atípicas son pocas y se ubican en regiones dispersas del espacio de datos, lo que las hace más fáciles de separar con menos particiones aleatorias.

El segundo método es DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*), que originalmente fue diseñado como algoritmo de agrupamiento e identifica como atípicos aquellos puntos que no logran integrarse a ningún clúster denso. Para ello, su funcionamiento se basa en dos parámetros: un radio de vecindad (usualmente denotado como ϵ) y un número mínimo de puntos que deben encontrarse dentro de ese radio para que una observación se considere parte de una región densa. Así, partir de estos parámetros, el algoritmo agrupa las observaciones que se encuentran suficientemente cerca unas de otras, formando clústeres de forma arbitraria, mientras que aquellos puntos que quedan aislados, sin suficientes vecinos cercanos, se clasifican como ruido o valores atípicos.

Y en tercer lugar están los autoencoders, que son redes neuronales entrenadas para reconstruir sus propias entradas, las cuales detectan anomalías cuando el error de reconstrucción es alto, lo que indica que la observación no se ajusta a los patrones aprendidos. Este método es particularmente útil con datos no estructurados como las imágenes, el texto o las señales.

En la tabla 1 pueden compararse los tres métodos abordados anteriormente y comparar para qué tipos de datos son apropiados.



Tabla 1*Comparativo de métodos de aprendizaje automático*

Criterio	Isolation Forest	DBSCAN	Autoencoder
Mecanismo	Árboles aleatorios que aíslan anomalías en pocas divisiones	Agrupar puntos densos. Los que no encajan en ningún clúster los detecta como ruido	Error alto al reconstruir la entrada indica anomalía
Tipo de dato	Tabulares, alta dimensionalidad	Datos con estructura espacial o geográfica	Imágenes, texto, señales, series de tiempo
Limitación principal	Menos efectivo con anomalías colectivas	Sensible al parámetro de densidad (ϵ)	Requiere gran volumen de datos de entrenamiento

La elección entre un método estadístico y uno de aprendizaje automático depende, por lo tanto, del volumen y dimensionalidad de los datos, de la interpretabilidad requerida y de si se dispone o no de ejemplos etiquetados de anomalías previas. Así, cuando se trabaja con conjuntos de datos pequeños, de baja dimensionalidad y con una distribución aproximadamente normal, es suficiente usar el Z-score o la visualización que, además, son más fáciles de explicar a públicos no técnicos. En cambio, cuando los datos son de alta dimensionalidad, no siguen una distribución conocida o no existen etiquetas previas que



indiquen qué observaciones son anómalas, es mucho mejor recurrir a métodos como *Isolation Forest* o DBSCAN, que identifican anomalías directamente a partir de la estructura o la densidad de los datos, sin necesidad de asumir una distribución específica ni de contar con ejemplos previamente clasificados.

Criterios para evaluar la calidad de los datos

Finalmente, es importante notar, como señalan Rahm y Do (2000), que los problemas de calidad de los datos pueden originarse tanto en una única fuente, por errores de entrada, formatos incorrectos o valores fuera de rango, o al integrar múltiples fuentes, donde surgen inconsistencias por diferencias de representación, duplicados y conflictos entre esquemas. Esto quiere decir que no basta con reconocer las anomalías para garantizar que se seleccionen datos de calidad, sino que también deben evaluarse otras dimensiones, como las siguientes:

- **La completitud:** se refiere a la ausencia de valores faltantes.
- **La consistencia:** alude a la coherencia entre registros y entre sistemas.
- **La exactitud:** referida a la correspondencia entre los datos y la realidad que pretenden representar.
- **La actualidad:** se refiere a la vigencia temporal de la información.
- **La unicidad:** se refiere a la ausencia de registros duplicados dentro de un mismo conjunto de datos.
- **La validez:** alude al cumplimiento de las reglas, formatos o rangos definidos para cada variable.

Intervenir cada una de estas dimensiones exige técnicas específicas. Por ejemplo, los valores faltantes pueden tratarse mediante eliminación de registros, imputación simple con la media o la mediana o

imputación múltiple cuando se requiere preservar la variabilidad estadística del conjunto; la consistencia se aborda mediante reglas de validación y procesos de conciliación entre fuentes; la exactitud se mejora con auditorías y contrastes con datos de referencia; y la actualidad, mediante políticas de actualización periódica y mecanismos de versionamiento. En la Tabla 2 se ejemplifican estas dimensiones y las técnicas que se pueden usar.

Tabla 2

Dimensiones de calidad de datos

Dimensión	Problema típico	Técnica principal	Ejemplo
Complejidad	Valores faltantes	Imputación (media, mediana, KNN) o eliminación de registros	Campo "edad" vacío en el 15% de registros
	Contradicciones entre fuentes o registros	Reglas de validación y conciliación entre sistemas	Fecha de nacimiento diferente en dos sistemas
Exactitud	Valores incorrectos respecto a la realidad	Auditorías y contraste con datos de referencia	Código postal que no corresponde a la ciudad
	Información desactualizada	Políticas de actualización y versionamiento	Dirección de cliente registrada hace 5 años
Unicidad	Registros duplicados	Detección de duplicados y deduplicación	Mismo cliente registrado dos veces



Validez	Valores fuera del rango o formato esperado	Reglas de dominio y transformación de formato	Edad = 300 o fecha = "32/13/2024"
----------------	--	---	-----------------------------------

A esto se le deben sumar las técnicas de estandarización, que llevan las variables numéricas a una escala común, y de normalización, que las ajustan a un rango específico, lo cual es indispensable para muchos algoritmos de minería de datos que son sensibles a las magnitudes de las variables. Finalmente, debe tenerse en cuenta que todo proceso de mejora de la calidad debe culminar con una validación posterior, que verifique que las intervenciones realizadas efectivamente mejoraron el conjunto de datos sin introducir sesgos nuevos, lo cual se va a profundizar más adelante.

En conclusión, la calidad de un proyecto de minería de datos se juega, en gran medida, al identificar con qué datos se cuenta y qué tan preparados están para sostener un análisis confiable. De allí la importancia de seleccionar las fuentes pertinentes, internas y/o externas, para asegurar que el análisis parta de información relevante; además, reconocer los datos anómalos, para advertir a tiempo qué tan confiables son esos datos; y evaluar dimensiones como la completitud, la consistencia, la exactitud, la actualidad, la unicidad y la validez para tener un panorama integral de su estado, más allá de los casos puntuales de anomalía. Estos tres momentos no son pasos aislados, sino etapas de un mismo ejercicio que antecede y hace posible cualquier intervención posterior sobre los datos.



Recursos de profundización

En el siguiente video se explica, desde un enfoque estadístico accesible, cómo evaluar la presencia de valores atípicos en un conjunto de datos y cuál es su impacto sobre las medidas de tendencia central y dispersión.

- Khan Academy en Español. (15 de enero de 2017). *Evaluación de valores atípicos y conjuntos de datos* [Video]. YouTube. www.youtube.com

En el siguiente recurso se describen las principales dimensiones de la calidad de los datos, los problemas más frecuentes que afectan su integridad y las estrategias recomendadas para su mejora dentro de proyectos de analítica de datos.

- IBM. (2023). *¿Qué es la calidad de los datos?* www.ibm.com

Recursos de profundización internacional

En el siguiente video, un científico de datos demuestra el funcionamiento del método *Isolation Forest* para la detección de anomalías, utilizando datos reales para ilustrar cómo el algoritmo aísla valores atípicos mediante árboles binarios de m.

- Elder Research, a MANTECH Company. (7 de marzo de 2023). *Isolation Forests: Identify outliers in data* [Isolation Forests: Identifica valores atípicos en los datos] [Archivo de video]. YouTube. www.youtube.com



En el siguiente artículo se presenta una explicación práctica del funcionamiento del algoritmo *Isolation Forest*, incluyendo su implementación en Python con Scikit-learn y ejemplos visuales que ilustran por qué los puntos anómalos requieren menos particiones para ser aislados que los puntos normales.

- Amol Mavuduru. (24 de noviembre de 2021). *How to perform anomaly detection with the Isolation Forest algorithm* [Cómo realizar detección de anomalías con el algoritmo Isolation Forest]. Towards Data Science. www.towardsdatascience.com

Referencias

- Chandola, V., Banerjee, A. y Kumar, V. (2009). Anomaly detection: A survey [Detección de anomalías: Una encuesta]. *ACM Computing Surveys*, 41(3), 1-58. www.dl.acm.org
- Fayyad, U., Piatetsky-Shapiro, G. y Smyth, P. (1996). From data mining to knowledge discovery: an overview [De la minería de datos al descubrimiento de conocimiento: una visión general]. En U. Fayyad, G. Piatetsky-Shapiro, G. Smyth y R. Uthurusamy (Eds.), *Advances in knowledge discovery and data Mining* [Avances en el descubrimiento de conocimiento y minería de datos] (pp. 1-34). AAAI Press / MIT Press.
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). Isolation forest. En *Eighth IEEE International Conference on Data Mining (ICDM)* (pp. 413-422). Institute of Electrical and Electronics Engineers.
- Rahm, E. y Do, H. H. (2000). Data cleaning: Problems and current approaches [Limpieza de datos: Problemas y enfoques actuales].



IEEE Data Engineering Bulletin, 23(4), 3–13.
www.static.cs.brown.edu

Shearer, C. (2000). The CRISP-DM model: The new blueprint for data mining [El modelo CRISP-DM: El nuevo plano para la minería de datos]. *Journal of Data Warehousing*, 5(4), 13–22.
www.ml4devs.com

Este curso incluye recursos visuales tomados de **Magnific**, plataforma para la cual la *Fundación Universitaria Católica del Norte* cuenta con una licencia premium vigente. Su uso se realiza conforme a los términos de licenciamiento establecidos; algunos recursos pueden haber sido generados o adaptados mediante herramientas de inteligencia artificial integradas en la misma plataforma.





CC BY-NC-ND 4.0 DEED

Attribution-NonCommercial-NoDerivs 4.0 International

Este OVA está protegido bajo la licencia **Creative Commons** Atribución – No Comercial – Sin Derivadas 4.0 Internacional (CC BY-NC-ND 4.0). Esto significa que:

- Debe otorgar crédito a la Fundación Universitaria Católica del Norte y experto(a) temático(a).
- No puede usarse con fines comerciales. Solo está permitido su uso no comercial.
- No está permitido generar obras derivadas (adaptaciones, transformaciones o reutilización parcial del contenido).

Para obtener más información sobre esta licencia, visitar el siguiente enlace: <https://creativecommons.org/licenses/by-nc-nd/4.0/>

Citación sugerida para el curso

Alzate Berrío, W. A. (2026). *Metodologías para Proyectos Data Mining* [OVA]. Fundación Universitaria Católica del Norte.



Católica del Norte
Fundación Universitaria